Projeto de Classificação de Frutas e Vegetais

Escola: Atlântico Avanti

Alunos:
Arthur Vale Fonseca e Samuel Cassiano de Abreu

Conteúdo: Módulo 3
Atividade: 04 - Projeto Final

Sumário

- Introdução
  - Informações do Dataset
- Metodologia
  - Métodos da Literatura e Ideias
  - Métodos da Literatura x Métodos Próprios
- Resultados
- Conclusões

Introdução

- Projeto de Classificação de Frutas e Vegetais

Introdução

Dataset contendo imagens de Frutas e Vegetais

- Imagens coletadas e geradas através do Bing

Motivação: Desenvolver um aplicativo capaz de reconhecer alimentos a partir de fotografias para sugerir receitas que podem ser preparadas com os ingredientes identificados.

Objetivo geral

- Analisar informações do Dataset
- Apresentar métodos da literatura, ideias e métodos próprios

Introdução

DISTRIBUIÇÃO GERAL DAS CLASSES:

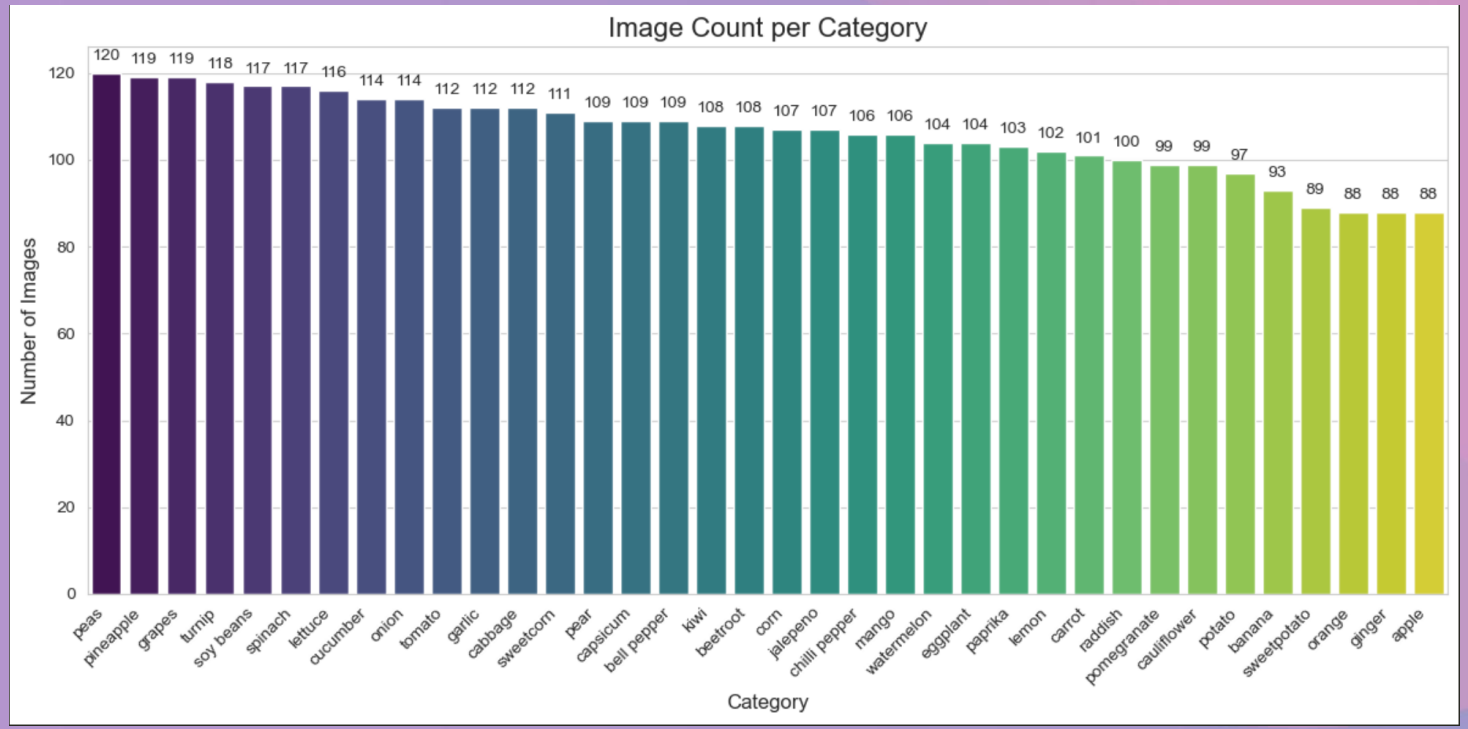

Metodologia

Informações Esperadas:

Total de 4320 imagens:

- 3600 separadas para treino;
- 360 para validação;
- 360 para teste.

Informações Encontradas:

```
# Function to calculate information for each folder
def get_folder_info(df, folder_name):
    folder_df = df[df['folder_name'] == folder_name]
    total_count = len(folder_df)
    duplicate_count = folder_df['img_hash'].duplicated().sum()
    return folder_name, total_count, duplicate_count

# Getting information for each folder
train_info = get_folder_info(df, 'train')
validation_info = get_folder_info(df, 'validation')
test_info = get_folder_info(df, 'test')

# Creating the table
data = [train_info, validation_info, test_info]
summary_table = pd.DataFrame(data, columns=['Folder', 'Total Quantity', 'Repeated Images'])

print(summary_table)
```

[78]

```
        Folder  Total Quantity  Repeated Images
0        train            3115              221
1   validation             351               26
2         test             359               26
```

Metodologia

MobileNetV2

- (CNN) projetada para ser leve e eficiente, tornando-a adequada para dispositivos móveis e embarcados.

Arquitetura:

- Blocos Residuais Invertidos
- Expansão Linear com Conexões Residuais

Aplicações:

- Classificação de imagens
- Detecção de objetos
- Segmentação semântica
- Reconhecimento facial

Eficiente e leve que é adequada para uma variedade de aplicações de visão computacional, especialmente em dispositivos móveis e embarcados.

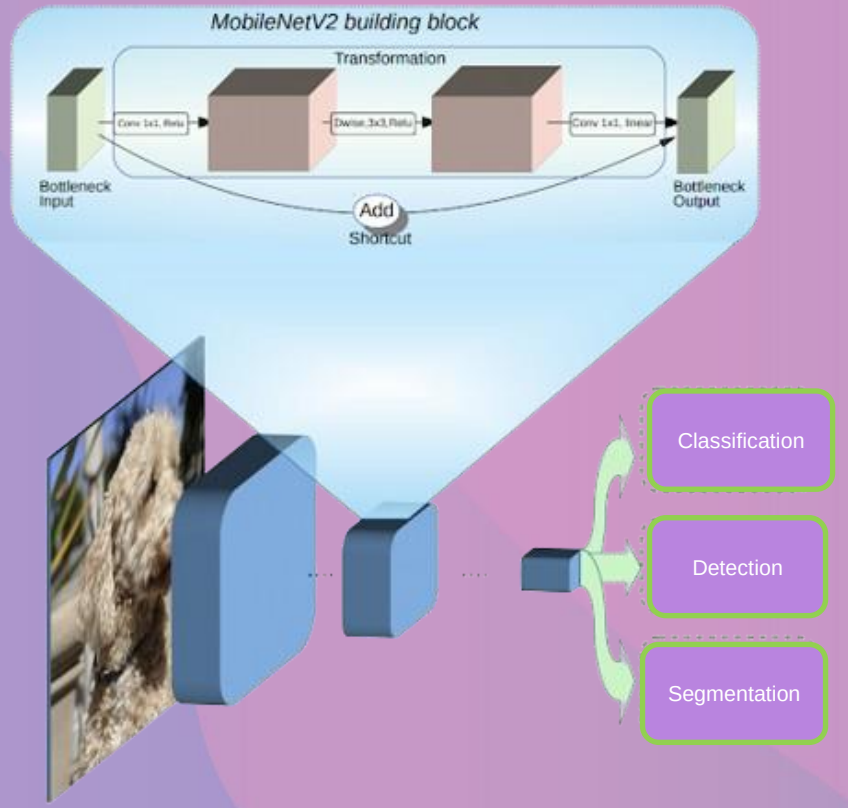

Metodologia

Vantagens:
- Leve e eficiente:
- Alta precisão:
- Rápida inferência:
- Fácil de implantar:

Limitações:
- Menos preciso em tarefas complexas
- Sensível a mudanças na resolução

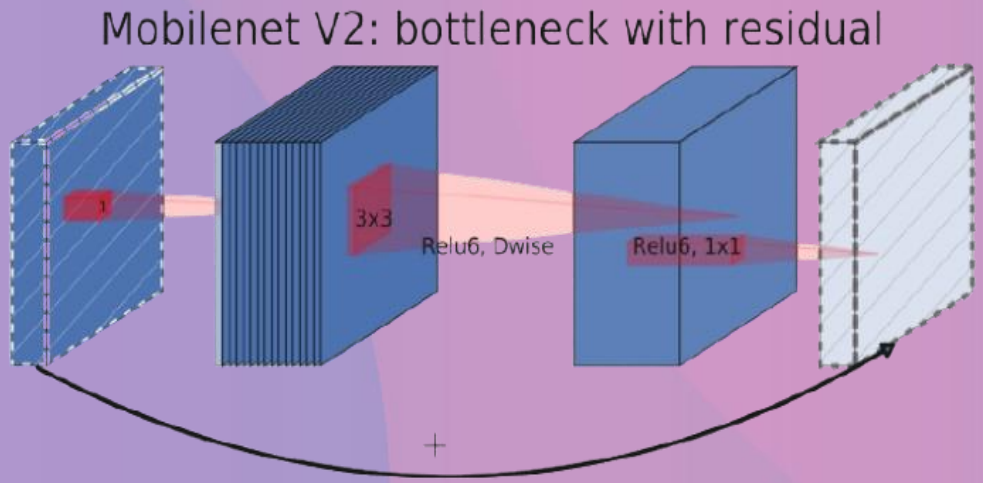

Eficiente e leve que é adequada para uma variedade de aplicações de visão computacional, especialmente em dispositivos móveis e embarcados.

Imagine um funil que se alarga e volta a se estreitar, deixando passar só o essencial.

Metodologia

MobileNetV3

- Versão ainda mais refinada e eficiente, construída com base nas lições aprendidas com as versões anteriores e incorporando novas técnicas.

- MobileNetV3-Large e MobileNetV3-Small

Arquitetura:

- Automated Neural Architecture Search (NAS)
- SE (Squeeze-and-Excitation) Modules
- Otimizações práticas
- Atualizações no uso de ativação

Aplicações:

- Classificação de imagens
- Detecção de objetos
- Segmentação semântica
- Reconhecimento facial

Carro híbrido que alterna entre o motor elétrico e a gasolina dependendo da necessidade, economizando combustível.

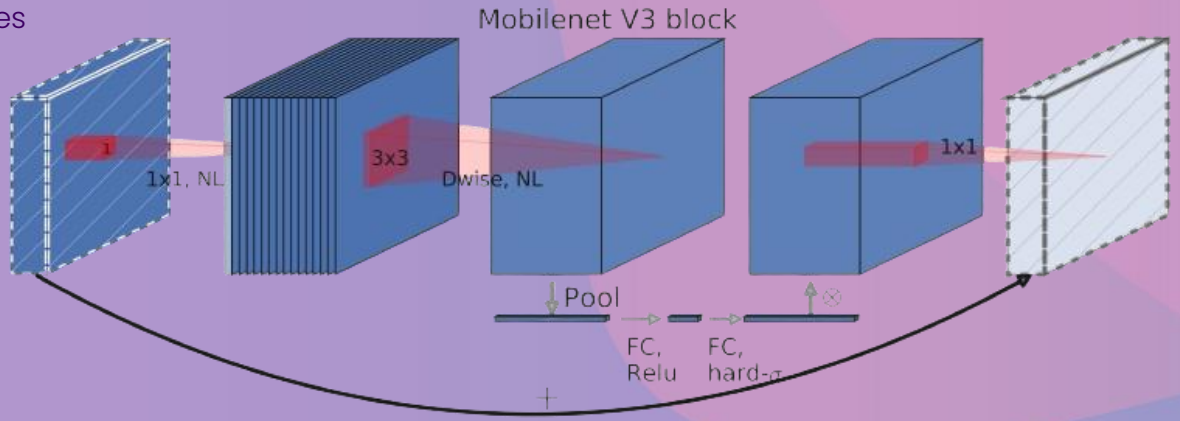

Resultados **MobileNetV2**

Resultados do modelo analisado com MobileNetV2:

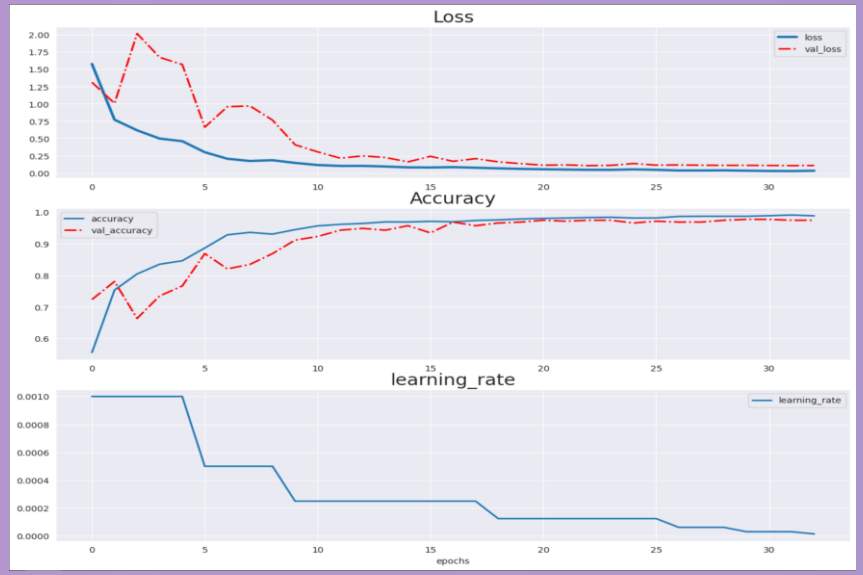


```
In [32]: evaluate_model_performance(best_model, validation_generator, classes)

11/11 [==============================] - 12s 985ms/step
                precision    recall  f1-score   support

         apple       0.82      0.90      0.86        10
        banana       1.00      0.78      0.88         9
      beetroot       1.00      1.00      1.00        10
   bell pepper       0.82      1.00      0.90         9
       cabbage       1.00      1.00      1.00        10
      capsicum       1.00      0.80      0.89        10
        carrot       1.00      1.00      1.00         9
   cauliflower       1.00      1.00      1.00        10
  chilli pepper       1.00      1.00      1.00         9
          corn       0.90      0.90      0.90        10
      cucumber       1.00      1.00      1.00        10
     eggplant       1.00      1.00      1.00        10
       garlic       1.00      1.00      1.00        10
       ginger       1.00      1.00      1.00        10
       grapes       1.00      1.00      1.00         9
     jalepeno       1.00      1.00      1.00         9
         kiwi       1.00      1.00      1.00        10
        lemon       0.91      1.00      0.95        10
      lettuce       1.00      1.00      1.00         9
        mango       0.91      1.00      0.95        10
        onion       1.00      1.00      1.00        10
       orange       1.00      1.00      1.00         9
      paprika       0.91      1.00      0.95        10
         pear       1.00      1.00      1.00        10
         peas       1.00      1.00      1.00        10
    pineapple       1.00      1.00      1.00        10
  pomegranate       1.00      1.00      1.00        10
       potato       1.00      0.80      0.89        10
      raddish       1.00      1.00      1.00         9
    soy beans       1.00      1.00      1.00        10
      spinach       1.00      1.00      1.00        10
    sweetcorn       0.90      0.90      0.90        10
  sweetpotato       1.00      1.00      1.00        10
       tomato       1.00      1.00      1.00        10
       turnip       1.00      1.00      1.00        10
   watermelon       1.00      1.00      1.00        10

     accuracy                           0.97       351
    macro avg       0.98      0.97      0.97       351
 weighted avg       0.98      0.97      0.97       351
```

Resultados **MobileNetV2**

Resultados do modelo analisado com MobileNetV2:

- Resultado dos Dados nos deixaram intrigados e procuramos analisar para entender melhor a razão desses resultados.

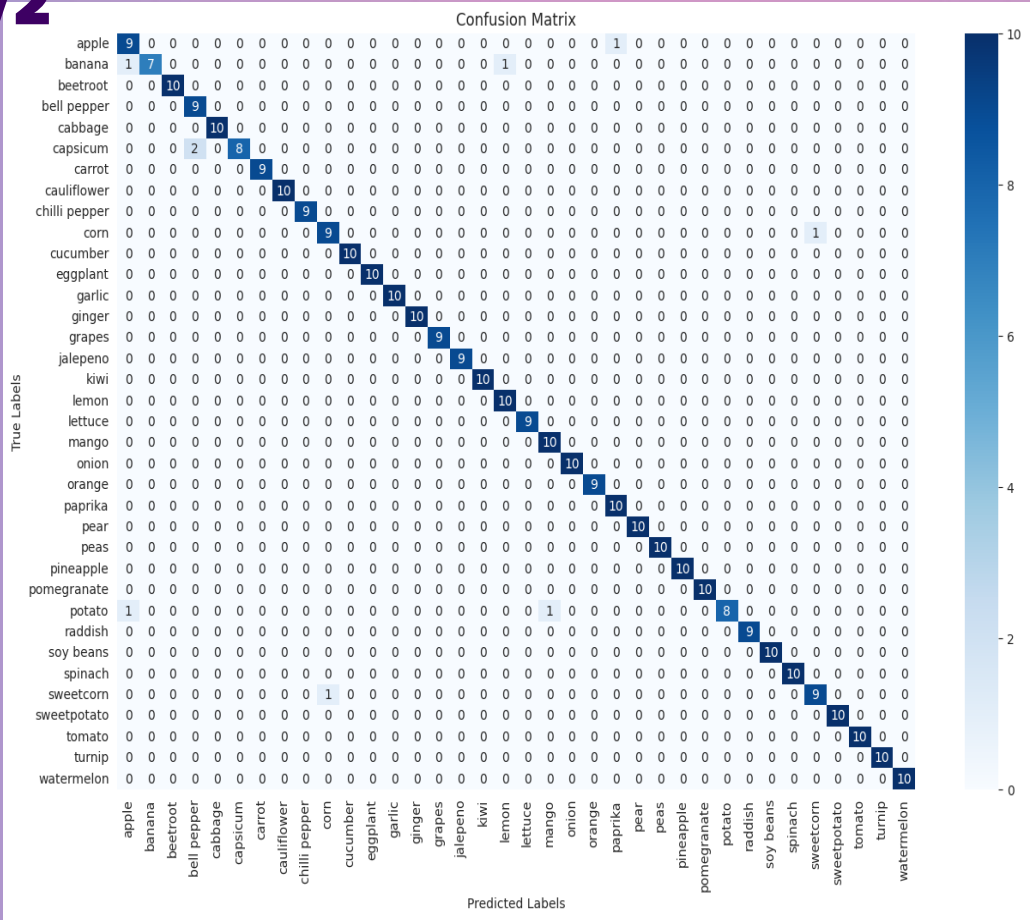

Resultados **MobileNetV2**

Resultados do modelo analisado com MobileNetV2

- Descobrimos que os dados de Validação eram idênticos aos de Teste.

O Modelo havia decorado todas as respostas do Teste e por esse motivo atingiu o resultado tão alto

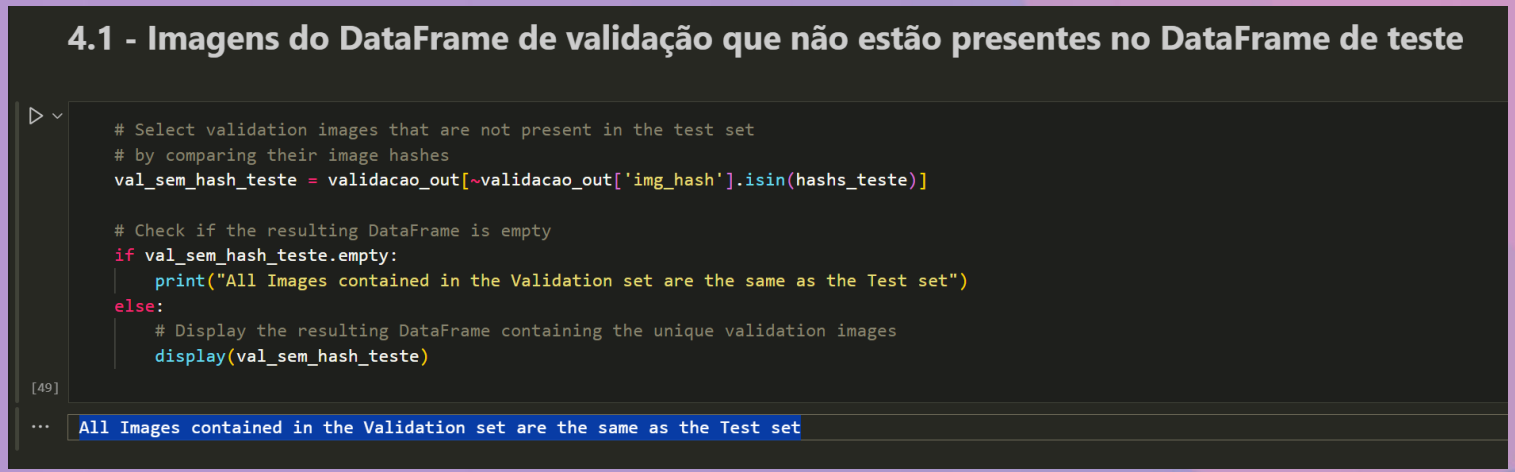

Resultados **MobileNetV3**

Nossos Resultados utilizando o modelo MobileNetV3:

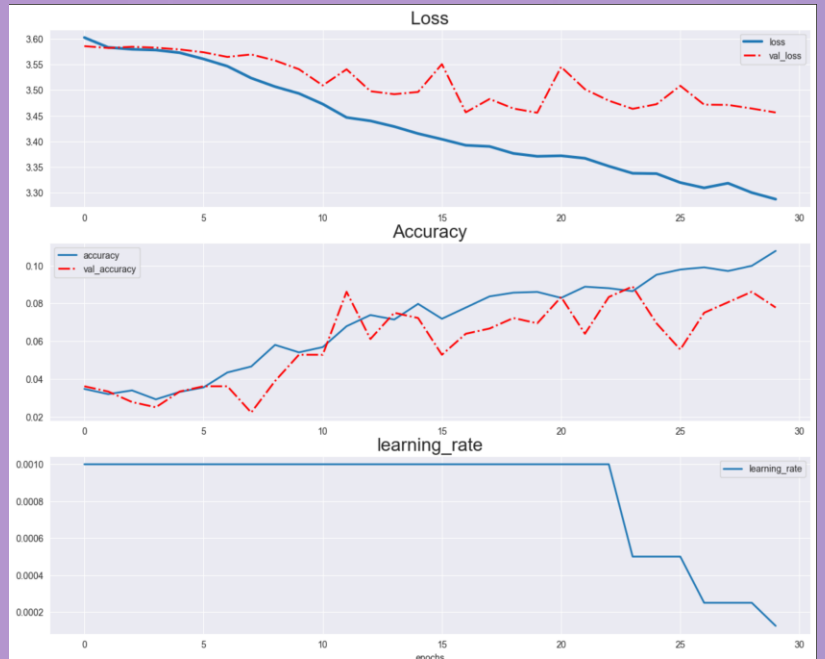


```
classes = [class_name for class_name in os.listdir(train_dir)]

evaluate_model_performance(best_model, validation_generator, classes)
```

```
12/12 ━━━━━━━━━━━━━━━━━━━━ 17s 1s/step
                precision    recall  f1-score   support

         apple       0.00      0.00      0.00        10
        banana       0.00      0.00      0.00        10
      beetroot       0.00      0.00      0.00        10
    bell pepper       0.05      0.10      0.07        10
       cabbage       0.00      0.00      0.00        10
      capsicum       0.00      0.00      0.00        10
        carrot       0.00      0.00      0.00        10
    cauliflower       0.00      0.00      0.00        10
  chilli pepper       0.00      0.00      0.00        10
          corn       0.00      0.00      0.00        10
      cucumber       0.00      0.00      0.00        10
      eggplant       0.25      0.20      0.22        10
        garlic       0.00      0.00      0.00        10
        ginger       0.00      0.00      0.00        10
        grapes       0.04      0.20      0.06        10
      jalepeno       0.05      0.20      0.08        10
          kiwi       0.00      0.00      0.00        10
         lemon       0.10      0.40      0.15        10
       lettuce       0.05      0.10      0.06        10
         mango       0.00      0.00      0.00        10
         onion       0.09      0.10      0.10        10
        orange       0.00      0.00      0.00        10
...
 weighted avg       0.03      0.07      0.04       360
```

Resultados **MobileNetV3**

Nossos Resultados utilizando o modelo MobileNetV3:

- Selecionamos 10 Classes

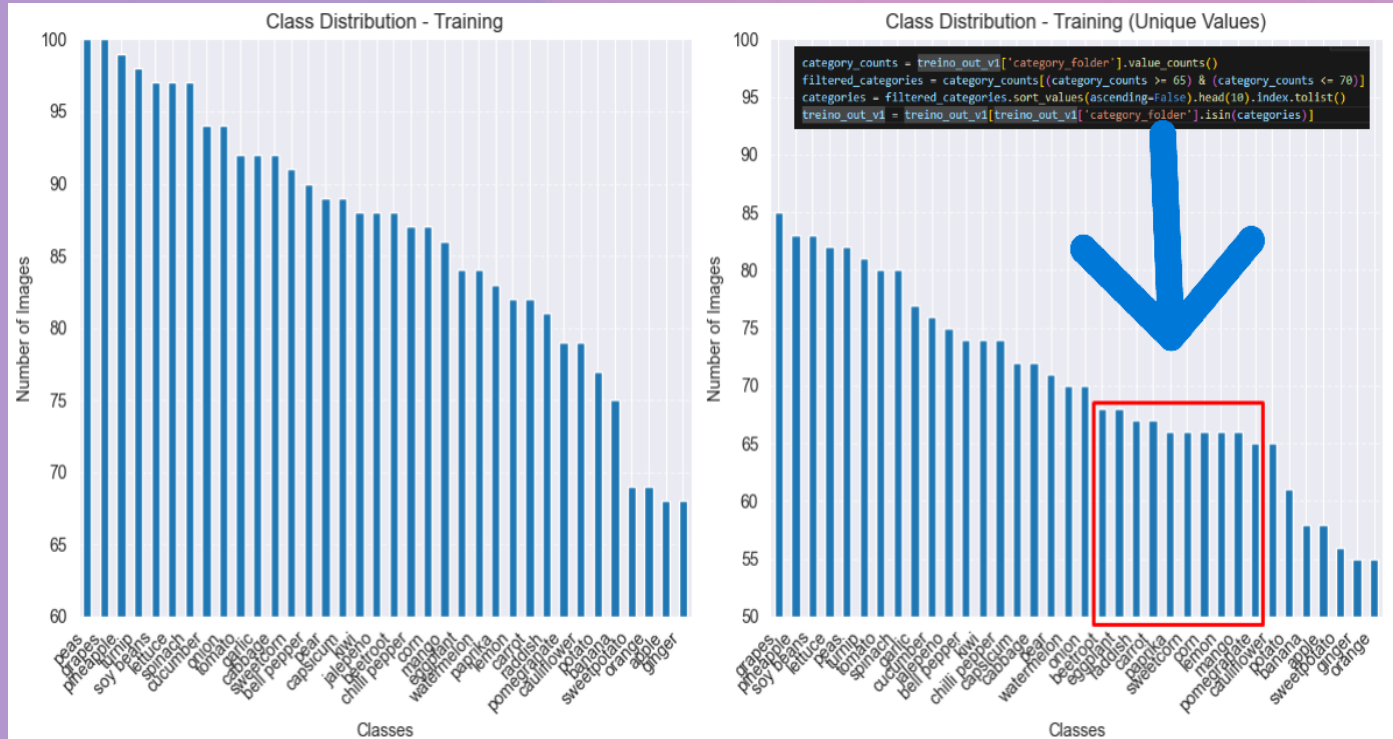

Resultados **MobileNetV3**

Nossos Resultados utilizando o modelo MobileNetV3:

- Selecionamos 10 Classes

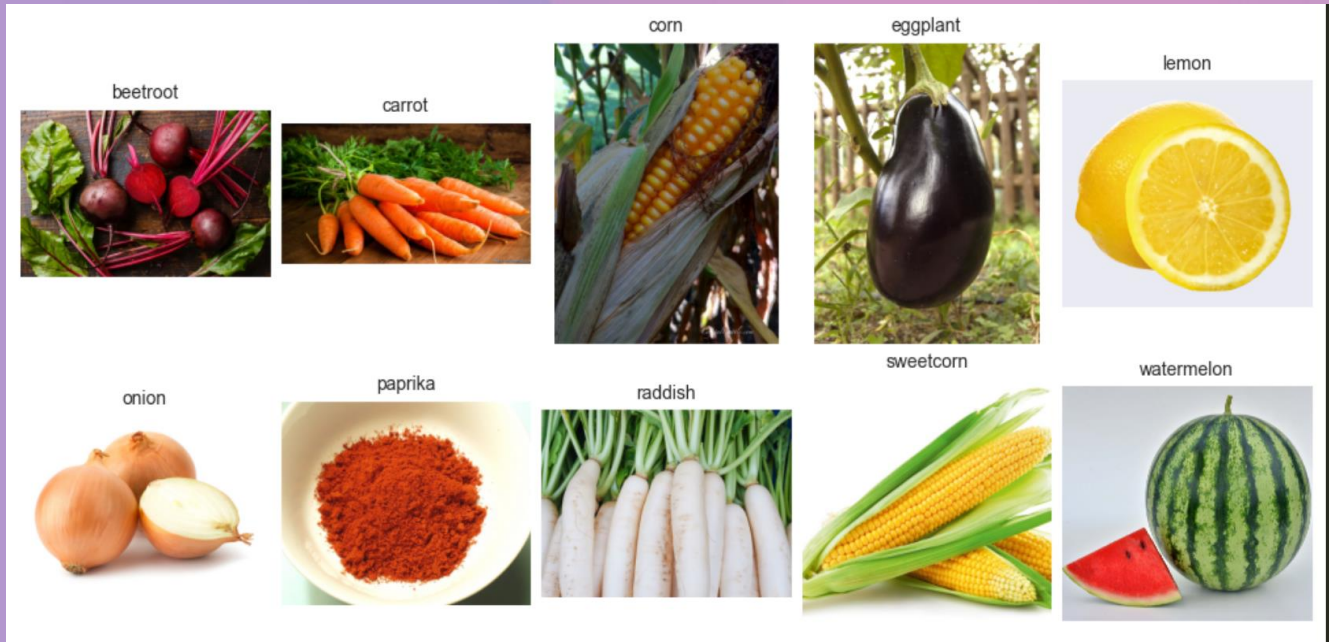

Resultados **MobileNetV3**

Nossos Resultados utilizando o modelo MobileNetV3:

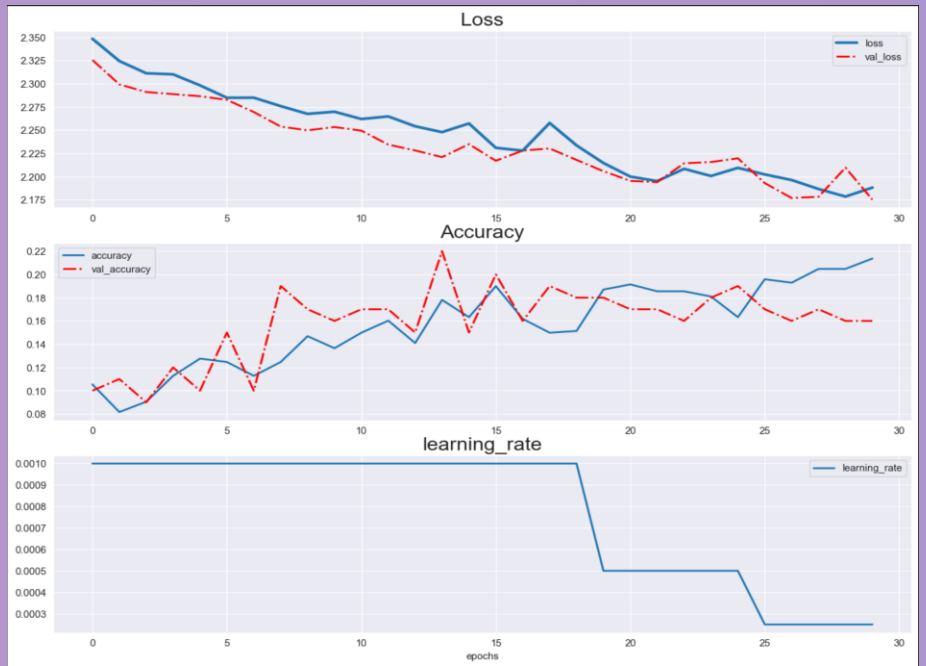


```
classes = [class_name for class_name in df_teste_no_dupli_v3['category_folder']]

evaluate_model_performance(best_model_2, validation_generator, classes)
```

```
4/4 ━━━━━━━━━━━━━━━━━━━━ 6s 1s/step
              precision    recall  f1-score   support

    beetroot       0.13      0.40      0.20        10
      carrot       0.05      0.10      0.06        10
        corn       0.20      0.10      0.13        10
    eggplant       0.24      0.50      0.32        10
       lemon       0.31      0.40      0.35        10
       onion       0.00      0.00      0.00        10
     paprika       0.00      0.00      0.00        10
     raddish       0.00      0.00      0.00        10
   sweetcorn       0.00      0.00      0.00        10
  watermelon       0.14      0.10      0.12        10

    accuracy                           0.16       100
   macro avg       0.11      0.16      0.12       100
weighted avg       0.11      0.16      0.12       100
```

Resultados **MobileNetV3**

Nossos Resultados utilizando o modelo MobileNetV3:

- Resultado Real e Final com a avaliação de 10 Classes de amostras dos.

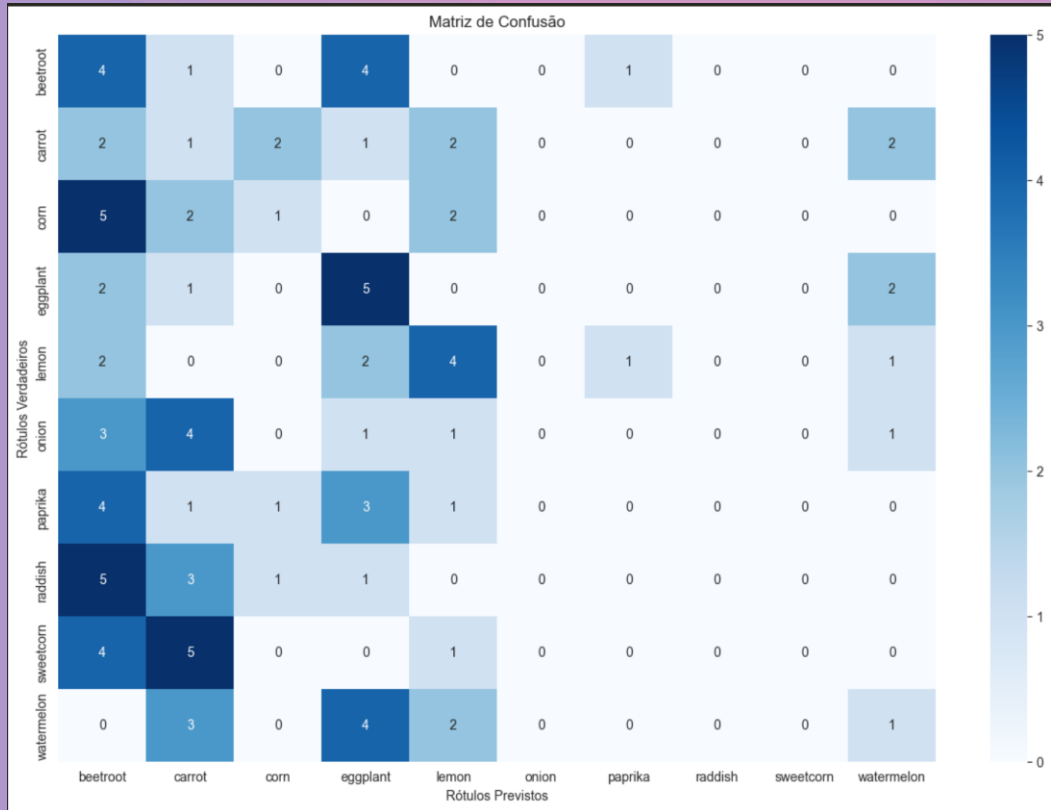

Conclusões

INFERÊNCIAS SOBRE O ESTUDO E LIÇÕES APRENDIDAS

- O Dataset modelo continha dados de validação idênticos ao teste;
- Os dados no mundo real nem sempre trarão métricas elevadas;
- Esses estudos poderão ser aprimorados e refinados.

Referências Bibliográficas

MobileNet, MobileNetV2, and MobileNetV3. Keras, Disponível em: <https://keras.io/api/applications/mobilenet/> 27 de nov. de 2024.

Simple MNIST convnet. Keras, Disponível em: <https://keras.io/examples/vision/mnist_convnet/> 27 de nov. de 2024.

Pyplot tutorial. matplotlib, Disponível em: <https://matplotlib.org/stable/tutorials/pyplot.html>. 27 de nov. de 2024.

Uma plataforma completa de machine learning. TensorFlow, Disponível em: <https://www.tensorflow.org/?hl=pt-br>. Acesso: 27 de nov. de 2024.

Atlântico Avanti

OBRIGADO!!!